tags: Machine Learning

Assignment 4

408410042 林靖紳

執行結果:

```
Training SVM with C = 100000, gamma = 100
Accuracy = 20% (20/100) (classification)
Training SVM with C = 100000, gamma = 1000
Accuracy = 13% (13/100) (classification)
Training SVM with C = 100000, gamma = 5000
Accuracy = 15% (15/100) (classification)
Training SVM with C = 150000, gamma = 100
Accuracy = 17% (17/100) (classification)
Training SVM with C = 150000, gamma = 1000
Accuracy = 26% (26/100) (classification)
Training SVM with C = 150000, gamma = 5000
Accuracy = 11% (11/100) (classification)
Training SVM with C = 200000, gamma = 100
Accuracy = 9% (9/100) (classification)
Training SVM with C = 200000, gamma = 1000
Accuracy = 4% (4/100) (classification)
Training SVM with C = 200000, gamma = 5000
Accuracy = 23% (23/100) (classification)
Training SVM with best parameters: C = 150000, gamma = 1000, accuracy = 26.0%
                 .....
Evaluating SVM with best parameters and scaling
Training SVM with C = 150000, gamma = 1000
Accuracy = 7% (7/100) (classification)
With scaling, accuracy = 7.00%
Evaluating SVM with best parameters without scaling
Training SVM with C = 150000, gamma = 1000
Accuracy = 0% (0/100) (classification)
Without scaling, accuracy = 0.00%
```

程式碼架構:

程式碼使用LIBSVM來訓練一個支援向量機(SVM)模型,並使用5-fold交叉驗證找到最佳的超參數C和gamma值,從而使得SVM模型最佳地適應數據。

該程式碼中包含了以下功能:

1. 生成一個線性模型及對應的數據集,並將數據格式化為 LIBSVM所需的格式。

```
In [2]: # Define the linear model

def linear_model(x):
    return = 2*x + np.rendom.normal(0, 1)

# Generate 500 data points with equal spacing in the range [-100, 100]

x = np.linspace(-100, 100, 500)

y = np.array([linear_model(xi) for xi in x])

# Plot the data
plt.scatter(x, y)
plt.xlabel('x')
plt.ylabel('x')
plt.ylabel('x')
plt.ylabel('y')
plt.title('500 Data Points Generated with Linear Model y = 2x + \varepsilon')

500 Data Points Generated with Linear Model y = 2x + \varepsilon'

500 Data Points Generated with Linear Model y = 2x + \varepsilon'
```

- 設定交叉驗證的折數及每折的數據集大小,然後進行數據 集的隨機切分。
- 3. 定義一個縮放數據的函數,用於將特徵值縮放到0到1之間。

4. 定義一個訓練和評估SVM模型的函數,其中訓練集和測試 集由交叉驗證生成,模型訓練通過LIBSVM庫實現,模型的 準確率通過測試集進行評估。

```
# Train and evaluate SVM models for all combinations of C and gamma
print('Training SVM with C = {}, gamma = {}'.format(c, gamma))

# Write the training and testing data to files
with open('train.dat', 'w') as f:
    for d in train_data:
        f.write('{} {}\n'.format(d['label'], ' '.join('{}:{}'.format(i+1, x) for i, x in enumerate(d['features']))))
with open('test.dat', 'w') as f:
    for d in test_data:
        f.write('{} {}\n'.format(d['label'], ' '.join('{}:{}'.format(i+1, x) for i, x in enumerate(d['features']))))

# Load the training and testing data from the files
y_train, x_train = svm_read_problem('train.dat')
y_test, x_test = svm_read_problem('test.dat')

# Train the SVM model
model = svm_train(y_train, x_train, '-s 0 -t 2 -c {} -g {}'.format(c, gamma))
```

- 5. 定義了一個超參數C和gamma的參數網格,從而可以通過 交叉驗證找到最佳的C和gamma參數值。
- 6. 最後,該程式碼使用最佳的C和gamma值來訓練SVM模型,並進行縮放和未縮放的模型評估,以比較模型的準確率。

結果討論

- 在支持向量機(SVM)中・C值和Gamma參數是用來調整模型的超參數。
 - C值是SVM的一個正則化參數,用於控制SVM對於錯 誤樣本的容忍度。當C值較大時,SVM會儘可能地讓 所有的樣本都分對,因此會出現過度擬合的情況;當 C值較小時,SVM會對錯誤樣本的容忍度較高,因此 可能會導致一些樣本分類錯誤。
 - Gamma參數是SVM中的一個核函數參數,用於控制 SVM的決策邊界的彎曲度。當Gamma值較大時, SVM的決策邊界會比較複雜,可能會導致過度擬合的 情況;當Gamma值較小時,SVM的決策邊界會比較 簡單,可能會導致欠擬合的情況。
- 從結果可以觀察到經過 scaling 的資料比沒有 Scaling 的 資料表現來的更好,這表示經過縮放後的資料可以更好的 幫助分類器找到最佳的邊界。
 - 推測原因: 在沒有經過特徵縮放的情況下,不同特徵 的取值範圍可能相差甚遠,這樣就會導致在不同特徵 下計算距離時對結果影響的程度也不一樣。
 - 透過特徵縮放,可以將所有特徵的範圍固定在一個區間內,使每個特徵在計算距離時對於結果的影響程度相對均衡,提高模型的穩定性。